

Apw 367

$$RSS = \frac{1}{2} \sum_{n=1}^N \left(y_n - \underbrace{(w^T x_n)}_{\substack{\text{scalair} \\ \text{label de la ligne } n}} \right)^2$$

$\hat{y}_n$
 1×1 $1 \times D$ $D \times 1$

y_n 1×1 scalair
 label de la ligne n
 w $D \times 1$ vecteur
 $\begin{pmatrix} x_{1I} \\ x_{1E} \\ x_{1D} \end{pmatrix}$ for D predictors

PRÉREQUIS: norme L_2 ou norme euclidienne

$$v = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_m \end{pmatrix}$$

Soit v vecteur $\|v\|_2 \triangleq \sqrt{v_1^2 + v_2^2 + \dots + v_m^2}$

Donc $\|v\|_2^2 = v_1^2 + v_2^2 + \dots + v_m^2$

ainsi $\|v\|_2^2 \triangleq v^T v$

1 w par predicteur

x_n $D \times 1$ vecteur
 $\begin{pmatrix} x_{1I} \\ x_{1E} \\ x_{1D} \end{pmatrix}$ for D predictors

Reprenons donc avec $Xw - y$

$N \times 1$
 vecteur

X $N \times D$ matrice

$$\|Xw - y\|_2^2 = \underbrace{\left(\underbrace{x_1}_{1 \times D} \underbrace{w}_{D \times 1} - \underbrace{y_1}_{1 \times 1} \right)^2}_{N \text{ termes}} + \dots + \left(x_N w - y_N \right)^2$$

$\begin{pmatrix} x_{1I} & x_{1E} & \dots & x_{1D} \\ x_{2I} & x_{2E} & \dots & x_{2D} \\ \vdots & \vdots & \ddots & \vdots \\ x_{NI} & x_{NE} & \dots & x_{ND} \end{pmatrix}$
 $D \times 1$ vecteur
 $N \times 1$ vecteur

$\Rightarrow$ L'ennui est que cela change la dimension de x
 (soit en haut: $D \times 1$)
 et ici $x = 1 \times D$

$\Rightarrow$ Utilisons les transposées pour rester cohérent.

$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}$ n labels des n rows du df .
 (voir plus haut)

$$\|Xw - y\|_2^2 = \underbrace{(w^T x_1)}_{1 \times 1} \underbrace{- y_1}_{1 \times 1}^2 + \dots + (w^T x_N - y_N)^2$$

n en a
 nouveau
 vecteur
 colonne
 $\begin{pmatrix} x_{1I} \\ x_{1E} \\ x_{1D} \end{pmatrix}$

$$= \sum_{n=1}^N (w^T x_n - y_n)^2$$

N termes

$$= \sum_{n=1}^N \left(\underbrace{y_n}_{\substack{\text{scalair} \\ 1 \times 1}} - \underbrace{(w^T x_n)}_{\substack{\text{scalair} \\ 1 \times 1}} \right)^2$$

$w^T x_n$
 $1 \times D$ $D \times 1$
 scalair 1×1

Donc $\frac{1}{2} \|Xw - y\|_2^2 = \frac{1}{2} \sum_{n=1}^N (y_n - w^T x_n)^2$

Par définition de L_2 :

$$\frac{1}{2} \|Xw - y\|_2^2 = \frac{1}{2} (Xw - y)^T (Xw - y)$$

$$\nabla_w \text{RSS}(w) = X^T X w - X^T y \quad ? \text{ PREUVE.}$$

- ANALOGIE AVEC SCALAIRES

$$\text{RSS}(w) = \frac{1}{2} (Xw - y)^T (Xw - y) \approx \frac{1}{2} (aw - y)^2$$

$$\begin{aligned} \Rightarrow \nabla_w \text{RSS}(w) &\approx \frac{\partial}{\partial w} \frac{1}{2} (a^2 w^2 + y^2 - 2awy) \\ &\approx \frac{1}{2} \cdot 2a^2 w - \frac{1}{2} \cdot 2ay \\ &\approx a^2 w - ay \end{aligned}$$

2 parties : 1) dévelop de RSS
2) gradient

$$X^T X w - X^T y$$

→ PREUVE A PARTIR de l'éq: $\text{RSS}(w) = \frac{1}{2} (Xw - y)^T (Xw - y)$

PRÉREQUIS 1) $(A-B)^T (A-B) = A^T A - 2A^T B + B^T B$
 $\approx (a-b)^2 = a^2 - 2ab + b^2$

2) $(AB)^T = B^T A^T$ (loi de TRANSPOSITION d'un PRODUIT)

$$\text{RSS}(w) = \frac{1}{2} (Xw - y)^T (Xw - y)$$

par prérequis 1)
$$= \frac{1}{2} \underbrace{(Xw)^T}_{1 \times N} \underbrace{Xw}_{N \times 1} - \frac{1}{2} \underbrace{y^T}_{1 \times N} \underbrace{Xw}_{N \times 1} + \frac{1}{2} \underbrace{y^T}_{1 \times N} \underbrace{y}_{N \times 1}$$

par prérequis 2)
$$= \frac{1}{2} w^T X^T X w - y^T X w + \frac{1}{2} y^T y$$

$X: N \times D$ mat.
 $w: D \times 1$ vecteur
 $y: N \times 1$ vecteur

PRÉREQUIS 3) $\nabla_w (b^T w) = b \approx \frac{\partial}{\partial w} aw = a$

PREUVE 1) $b^T w = \text{produit scalaire} = \sum b_i w_i$
 $1 \times D \quad D \times 1 \rightarrow 1 \times 1$

2) $\nabla_w (b^T w) = \begin{bmatrix} \frac{\partial}{\partial w_1} (b^T w) \\ \frac{\partial}{\partial w_2} (b^T w) \\ \vdots \\ \frac{\partial}{\partial w_D} (b^T w) \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_D \end{bmatrix} = b$

$\frac{\partial}{\partial w_1} (b^T w) = \frac{\partial}{\partial w_1} (b_1 w_1 + b_2 w_2 + \dots + b_D w_D)$
 $= b_1$

4) $\nabla_w (w^T A w) = 2Aw$ (si A symétrique) $\approx f(w) = aw^2 \rightarrow f'(w) = 2aw$
 Preuve: Soit $A \in \mathbb{R}^{2 \times 2}$, $w = \begin{pmatrix} w_1 \\ w_2 \end{pmatrix}$, $A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$

$f(w) = w^T A w = a_{11} w_1^2 + (a_{12} + a_{21}) w_1 w_2 + a_{22} w_2^2$
 $\nabla_w f(w) = \begin{pmatrix} \frac{\partial f}{\partial w_1} = 2a_{11} w_1 + (a_{12} + a_{21}) w_2 \\ \frac{\partial f}{\partial w_2} = 2a_{22} w_2 + (a_{12} + a_{21}) w_1 \end{pmatrix}$

Si A symétrique: $a_{12} = a_{21} \rightarrow \nabla_w f(w) = \begin{pmatrix} 2a_{11} w_1 + 2a_{12} w_2 \\ 2a_{21} w_1 + 2a_{22} w_2 \end{pmatrix} = 2Aw$

Reprenons avec la deuxième partie.

Rappel : $RSS(w) = \frac{1}{2} w^T X^T X w - y^T X w + \frac{1}{2} y^T y$

$\nabla_w RSS(w) = \nabla_w \left(\frac{1}{2} w^T \underbrace{X^T X}_{\substack{D \times N \quad N \times D \quad D \times D \\ \text{mat } D \times D \\ \text{symétrique}}} w \right) - \nabla_w \left(\underbrace{y^T X}_{1 \times N \quad N \times D} w \right) + \nabla_w \left(\frac{1}{2} y^T y \right)$

Dérivée d'une fonction scalaire par un vecteur $D \times 1$

output $D \times 1$

$= \frac{1}{2} \cdot 2 \cdot \underbrace{X^T X}_A w$

par (4)

$- y^T X ?$

par (3)

coefficient de la variable (cas a)

non! Attention aux dimensions!

$\rightarrow -X^T y$ (au lieu de $y^T X$)

$= 0$ (pas fonction de w)

$\nabla_w RSS(w) = X^T X w - X^T y$

$D \times 1$ $D \times 1$

GEOMETRIC INTERPRETATION of LEAST SQUARES

A ce stade nous connaissons la valeur de y , mais pas son équation, nous ne la connaissons d'ailleurs jamais.

Concernant y , nous connaissons son équation mais pas encore sa valeur.
Concernant w , là aussi on ne connaît pas encore sa valeur.

Concernant (C), là aussi on ne connaît pas encore la valeur

avec $\hat{y} = X(\hat{w})$

NORMAL EQUATIONS

↳ en substituant par ω , on va trouver la valeur de ω qui annule la dérivée, et qui minimise la RSS (ω)

Preons l'exemple (très mal fait d'ailleurs) 11,3 comme base de travail.

Sei $N = 3$, $D = 2$

N lignes $\begin{cases} m=1 \\ m=2 \\ m=3 \end{cases}$ $\begin{matrix} \vec{x}_I \\ \vec{x}_{1I} \\ \vec{x}_{2I} \\ \vec{x}_{3I} \end{matrix}$ $\begin{matrix} \vec{x}_{II} \\ \vec{x}_{1II} \\ \vec{x}_{2II} \\ \vec{x}_{3II} \end{matrix}$ $\begin{matrix} \vec{y} \\ y_1 \\ y_2 \\ y_3 \end{matrix}$ $\begin{matrix} \text{var} \\ \text{var} \\ \text{coeff} \\ \text{var} \end{matrix}$ $\begin{matrix} \vec{y} \\ y_1 \\ y_2 \\ y_3 \end{matrix} = \begin{matrix} \omega_I \\ \omega_{II} \\ \omega_I \\ \omega_{II} \end{matrix} \begin{matrix} \vec{x}_{1I} \\ \vec{x}_{2I} \\ \vec{x}_{3I} \\ \vec{x}_{1II} \\ \vec{x}_{2II} \\ \vec{x}_{3II} \end{matrix}$ $\vec{y} = \omega \cdot \vec{x}$ (exemple m.)

Donc $\begin{matrix} \vec{y} \\ y_1 \\ y_2 \\ y_3 \end{matrix}_{N \times 1} = \begin{matrix} \omega_I \\ \omega_{II} \\ \omega_I \\ \omega_{II} \end{matrix}_{1 \times 1} \begin{matrix} \vec{x}_I \\ \vec{x}_{1I} \\ \vec{x}_{2I} \\ \vec{x}_{3I} \end{matrix}_{N \times 1} + \begin{matrix} \omega_{II} \\ \omega_I \\ \omega_{II} \\ \omega_I \end{matrix}_{1 \times 1} \begin{matrix} \vec{x}_{II} \\ \vec{x}_{1II} \\ \vec{x}_{2II} \\ \vec{x}_{3II} \end{matrix}_{N \times 1}$

$\vec{y} = \omega \cdot \vec{x}$ No $\vec{y} = \vec{x} \cdot \omega$ $\begin{matrix} N \times D \\ N \times 1 \end{matrix}$

= 2 bases du sous-espace de $\mathbb{R}^3$
 = 2 bases du plan

Re-analyse cette équation:

$$\vec{y} = w_{\perp} \vec{e}_{\perp} + w_{\parallel} \vec{e}_{\parallel}$$

→ Tout les vecteurs appartenant au plan (sans espace), et un y sera le plus proche des vecteurs $\vec{y}$


Visuellment: von notebook: projection - subspace - regression ifylw

Le truc **très important** : L'espace $\mathbb{R}^3$ n'est pas (x_1, x_2, y) (exemple de m) !!
mais **composante 1** **composante 2** et **composante 3**.
($m=1, 2 \leq m \leq N$)

Donc $\vec{y} = (y_1, y_2, y_3)$ est un vecteur dans $\mathbb{R}^3$ avec y_1 valeur sur l'axe
composante 1, y_2 sur l'axe comp. 2 et y_3 comp. 3

Donc les vecteurs $\begin{pmatrix} \vec{e}_I \\ 1 \end{pmatrix}$ et $\begin{pmatrix} \vec{e}_{II} \\ 1 \end{pmatrix}$ sont des sous-espaces (des droites de $\mathbb{R}^3$)

Ces solutions forment un plan contenant tous les $\vec{y}$ possibles (Comb. linéaire)



en log = ln

ECRITURES de $l(\theta)$ (LOG-LOSS)

Nomenclature N vs N_{ex}

$$l(w) = - \sum_{i=1}^N \left[y_i \log \frac{h(x_i)}{1-h(x_i)} + (1-y_i) \log \frac{1-h(x_i)}{h(x_i)} \right]$$

$$\begin{pmatrix} w \\ N \end{pmatrix}$$

je ne fais cette écriture

avec $h_w(x) = h(x)$
 $\frac{1}{1+e^{-wx}}$
 $\rightarrow \tau$
 apparemment on le selon
 chat GT mais je continuais d'écrire log

$$w = \theta \quad D \times 1$$

$$X \quad N \times D$$

$$y \quad N \times 1$$

$$h_w(x) = \sigma(w^T x) \quad 1 \times 1$$

$$h_w(X) = \tau(Xw) \quad N \times 1$$

SIGMOÏDE

SIGMOÏDE

$$= \sum_{i=1}^N y_i \log(h_w(X)) + (1-y_i)^T \log(1-h_w(X))$$

$1-y$: opérations
 et log
 cherché à
 montrer
 dimensions
 cohérentes.

avec $h_w(X) = \tau(Xw) = \frac{1}{1+e^{-Xw}}$
 $N \times 1$

DÉRIVÉE de $l(\theta)$ par w

Comparons pour rappel à la régression linéaire

Reg Lin: $h_w(x) = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_D x_D \quad (\approx w_1 x_1 + w_2 x_2 + \dots + w_D x_D)$

$$h_w(x) = \sum w_i x_i = w^T x$$

Log Reg: $h_w(x) = \frac{1}{1+e^{-w^T x}}$

DONC: Au lieu d'avoir une fonction de w , nous avons une composition de fonctions:

$$w \xrightarrow{z=w^T x} z \xrightarrow{\tau} h \xrightarrow{\log} l$$

$\Rightarrow$ On doit appliquer la chaîne de composition

$$\nabla_w l(w) = \frac{dl}{dw} = \frac{dl}{dh} \cdot \frac{dh}{dz} \cdot \frac{dz}{dw}$$

$$\textcircled{1} \frac{dl}{dh}$$

$$l(h) = - \sum y_i \log h + (1-y_i)^T \log(1-h)$$

$$\frac{d \ln(x)}{dx} = \frac{1}{x}$$

donc ce ne sont pas vraiment des logs -

$$\frac{dl}{dh} l(h) = - \sum y_i \cdot \frac{1}{h} + \frac{(1-y_i)^T}{1-h}$$

dimensions marchent

$$= - \frac{y}{h} + \frac{1-y}{1-h}$$

divisons élément par élément,
 HADAMARD

dérivée de la
 log-loss par rapport
 au sigmoïde
 à la sigmoïde

② $\frac{dh}{dz}$

$$h = \frac{1}{1+e^{-z}} \quad z = \sigma(z) = \sigma(Xw) = \sigma(w^T x)$$

Posez $u(z) = 1+e^{-z}$

$$h = \frac{1}{u(z)}$$

$$\Rightarrow \frac{\partial h}{\partial z} = \frac{\partial}{\partial z} \left(\frac{1}{u(z)} \right) = - \frac{u'(z)}{u^2(z)}$$

dérivée quotient.
avec $u'(z) = -e^{-z}$

$$\text{on } h = \frac{1}{(1+e^{-z})}$$

$$= - \frac{-e^{-z}}{(1+e^{-z})^2} = \frac{e^{-z}}{(1+e^{-z})^2}$$

$$= h \cdot \frac{e^{-z}}{(1+e^{-z})}$$

$$= h \cdot (1-h)$$

$$1-h = 1 - \frac{1}{1+e^{-z}} = \frac{1+e^{-z}-1}{1+e^{-z}} = \frac{e^{-z}}{1+e^{-z}}$$

Ceci était par le développement des éléments individuels du jacobien

En réalité, $\frac{\partial h}{\partial z} \stackrel{N \times 1}{=} \text{jacobien } N \times N$

Ainsi, si $h = \begin{bmatrix} h_1 \\ h_2 \\ h_3 \\ h_4 \end{bmatrix} \stackrel{N \times 1}{=} \begin{bmatrix} \sigma(z_1) \\ \sigma(z_2) \\ \sigma(z_3) \\ \sigma(z_4) \end{bmatrix}$

Alors $\frac{\partial h}{\partial z} = \begin{bmatrix} \frac{\partial h_1}{\partial z_1} & \frac{\partial h_1}{\partial z_2} & \frac{\partial h_1}{\partial z_3} & \frac{\partial h_1}{\partial z_4} \\ \frac{\partial h_2}{\partial z_1} & \frac{\partial h_2}{\partial z_2} & \frac{\partial h_2}{\partial z_3} & \frac{\partial h_2}{\partial z_4} \\ \frac{\partial h_3}{\partial z_1} & \frac{\partial h_3}{\partial z_2} & \frac{\partial h_3}{\partial z_3} & \frac{\partial h_3}{\partial z_4} \\ \frac{\partial h_4}{\partial z_1} & \frac{\partial h_4}{\partial z_2} & \frac{\partial h_4}{\partial z_3} & \frac{\partial h_4}{\partial z_4} \end{bmatrix}$

Mais comme $h_i = \sigma(z_i)$ dépend uniquement de z_i :

$$\frac{\partial h_i}{\partial z_j} = \begin{cases} \frac{d}{dz_i} \sigma(z_i) = h_i(1-h_i) & i=j \\ 0 & i \neq j \end{cases}$$

Avec $\frac{\partial h}{\partial z} = \begin{bmatrix} h_1(1-h_1) & 0 & 0 & 0 \\ 0 & h_2(1-h_2) & 0 & 0 \\ 0 & 0 & h_3(1-h_3) & 0 \\ 0 & 0 & 0 & h_4(1-h_4) \end{bmatrix}$

$$\left(\frac{\partial h}{\partial z} \right)_{ij} = \delta_{ij} \cdot h_i(1-h_i) \quad \text{avec } \delta_{ij} = \begin{cases} 1 & i=j \\ 0 & \text{sinon} \end{cases}$$

De manière générale, pour $\frac{\partial h}{\partial z}$ avec $h = h_w(x)$ et $z = Xw$

$$\frac{\partial h}{\partial z} = \text{diag}(h \odot (1-h))$$

$h \odot (1-h)$ est le vecteur "élément par élément" du jacobien, car on calcule les dérivées.

On voit quand on travaille élément par élément que les éléments se multiplient dans le vecteur, on écrit $\odot$ pour bien différencier des autres notations.

$$\textcircled{3} \quad \begin{aligned} \underset{1 \times 1}{Z} &= \underset{1 \times D}{\omega^T} \underset{D \times 1}{\theta} \\ \underset{1 \times 1}{\frac{\partial Z}{\partial \omega}} &= \theta \end{aligned} \quad \begin{aligned} \underset{N \times 1}{\vec{Z}} &= \underset{N \times D}{X} \underset{D \times 1}{\omega} \\ \underset{N \times 1}{\frac{\partial \vec{Z}}{\partial \omega}} &= X \end{aligned}$$

REGROUPEONS les 3 dernières

$$\nabla_{\omega} \ell = \left[\underbrace{\left(-\frac{y}{h} + \frac{1-y}{1-h} \right)^T}_{1 \times N} \underbrace{\text{diag}(h \odot (1-h))}_{N \times N} \underbrace{X^T}_{N \times D} \right]^T$$

produit et quotients HADAMARDS (élément par élément) → conserve dimensions

$$D \times 1 = \left[1 \times N \quad N \times N \quad N \times D \right]^T$$

Traçons la partie suivante: $\left(-\frac{y}{h} + \frac{1-y}{1-h} \right)^T \text{diag}(h \odot (1-h))$

$$\approx \underset{1 \times N}{[x_1 \ x_2 \ x_3]} \underset{N \times N}{\begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix}} = [ax_1 + dx_2 + gx_3 \quad bx_1 + ex_2 + hx_3 \quad cx_1 + fx_2 + ix_3]$$

Soit $\left(-\frac{y}{h} + \frac{1-y}{1-h} \right)^T = \left[\left(-\frac{y_1}{h_1} + \frac{1-y_1}{1-h_1} \right) \quad \left(-\frac{y_2}{h_2} + \frac{1-y_2}{1-h_2} \right) \quad \dots \right]$ *vecteur ligne et non colonne ($\cdot^T$)*

Soit $\text{diag}(h \odot (1-h)) = \begin{bmatrix} h_1(1-h_1) & 0 & 0 \\ 0 & h_2(1-h_2) & 0 \\ 0 & 0 & h_3(1-h_3) \end{bmatrix}$

Donc le produit est: $1 \times N$ (vecteur ligne)

$$\left[\left(-\frac{y_1}{h_1} + \frac{1-y_1}{1-h_1} \right) h_1(1-h_1) \quad 0 + f(y_2, h_2) + 0 \quad 0 + 0 + f(y_3, h_3) \right]$$

$$+ \left(-\frac{y_2}{h_2} + \frac{1-y_2}{1-h_2} \right) \cdot 0$$

$$+ \left(-\frac{y_3}{h_3} + \frac{1-y_3}{1-h_3} \right) \cdot 0$$

Chaque élément du vecteur:

$$\left(-\frac{y_1}{h_1} + \frac{1-y_1}{1-h_1} \right) \cdot h_1(1-h_1) \stackrel{\text{m'annule}}{=} \left(\cancel{-y_1 + y_1 h_1 + h_1 - y_1 h_1} \right) \left(\cancel{h_1(1-h_1)} \right)$$

$$= h_1 - y_1$$

→ Vecteur $= \underset{1 \times N}{[h_1 - y_1 \quad h_2 - y_2 \quad h_3 - y_3]}$

Il reste plus qu'à multiplier par X pour obtenir $\nabla_{\omega} \ell$

$$\nabla_{\omega} \ell = X^T (h - y)$$

Développement selon Andrew Ng: $\frac{\partial \ell}{\partial \theta}$

$$\frac{\partial}{\partial \theta_j} \ell(\theta) = \left(y \frac{1}{g(\theta^T x)} - (1-y) \frac{1}{1-g(\theta^T x)} \right) \left(\frac{\partial}{\partial \theta_j} g(\theta^T x) \right)$$

Gradient scalaire
(version différente
de notre gradient
vectorel)

$$= \left(\dots \right) \underbrace{g(\theta^T x) (1-g(\theta^T x))}_{\frac{\partial h}{\partial z}} \cdot \underbrace{\frac{\partial}{\partial \theta_j} (\theta^T x)}_{x_j} \cdot \frac{\partial z}{\partial \theta_j}$$

1×1

$$= \underbrace{(y - h_0(x))}_{1 \times 1 \text{ (scalaire)}} \underbrace{x_j}_{1 \times 1 \text{ (scalaire)}} \underbrace{1}_{1 \times 1}$$

un élément de

$$\underbrace{\frac{\partial \ell}{\partial \theta}}_{1 \times D} \text{ ou } \underbrace{\frac{\partial \ell}{\partial w}}_{1 \times D} \text{ (Grad vectorel)}$$

(ici, c'est $\frac{\partial \ell}{\partial \theta_j}$ ou $\frac{\partial \ell}{\partial w_j}$)
(Gradient scalaire)

THE EXPONENTIAL FAMILY

La régression linéaire et logistique ne sont que 2 cas particuliers d'une (grande) famille de modèles, la famille **EXPONENTIELLE**

$$p(y; \eta) = b(y) e^{\underbrace{\eta^T T(y)}_{\text{dot product}} - \underbrace{a(\eta)}_{\text{log partition function}}}$$

$a(\eta)$: 'log partition function' ou 'fonction de normalisation logarithmique'.
Elle fait en sorte que la probabilité soit bien normalisée, c-à-d :

$$\sum_y p(y; \eta) = 1 \quad (\text{discret}) \quad \text{ou} \quad \int p(y; \eta) dy = 1 \quad (\text{continu})$$

- Ex. dans la loi de Bernoulli, $a(\eta) = \log(1 + e^\eta)$, ce qui amène que :
 $p(y=0) + p(y=1) = 1$

- Relations :

$$a) \underbrace{E(T(y))}_{D \times D} = \underbrace{\nabla_{\eta} a(\eta)}_{D \times 1}$$

$$b) \text{Var}(T(y)) = \nabla^2 a(\eta)$$

'la matrice de variance/covariance de $T(y)$ est égale à la matrice hessienne (matrice des dérivées secondes) de $a(\eta)$ (par rap. à η)

$T(y)$: 'statistique suffisante de y ', souvent $T(y) = y$

- Dans certains cas, $T(y) \propto y$.

a) Distribution Γ (gamma) : $p(y; \eta) = e^{\underbrace{[\eta_1 T(y)]}_{\text{prod. scalaire}} - a(\eta) + b(y)}$

Remarque : $T(y)$ = vecteur naturel

Donc $T(y) = \begin{bmatrix} \log y \\ y \end{bmatrix}$ ici (et $\eta = \begin{bmatrix} \eta_1 \\ \eta_2 \end{bmatrix}$)

b) Multinomial (multinomiale à 1 case) : $y \in \{1, 2, \dots, K\}$

On encode souvent y en ONE-HOT vector.

$T(y)$ = vecteur indicateur (facteur)

$$T(y) = [1\{y=1\}, \dots, 1\{y=K-1\}]$$

- 'paramètre naturel' et 'canonical parameter'
- Contrairement à $T(y)$, $a(\eta)$ et $b(\eta)$, il n'influence PAS la famille de la distribution

- DONC, en fixant $T(y)$, $a(y)$ et $b(y)$,

Ex: - faire varier η pour la famille "Normale" va faire varier μ et σ^2

-	n	n	n	'Polson'	n	n	x
-	n	n	n	'Gamma'	n	n	x erf

- Dans les GLM: η est imposé à $X\beta$
 $\neq$ modèle bayésien - ω_{β}

$b(\eta)$: - absorbe les termes ne dépendant que de η
 $p(\eta; \eta) = b(\eta) \cdot \exp(\underbrace{\eta^T T(\eta)}_{\text{caylage}} - \underbrace{a(\eta)}_{\text{dépend que de } \eta})$

$\Rightarrow$ permet de reformuler facilement une distribution connue en forme exponentielle

- aucun effet sur l'appariage (on le gère par la fonction d' w_{ij})

- analogue de $a(\eta)$ mais par l'équilibre en y